ÉQUIPE GLUCOSCAN

Dépistage du diabète

Prédire le risque à partir de 8 mesures médicales simples

UMEF AI Bootcamp · Demo Day



Photo : David-i98, CC BY-SA 3.0, Wikimedia Commons

Le problème : repérer le risque tôt



Que prédit-on ?

Diabétique (1) ou non (0) → classification



Pour qui ?

Centres de santé, pharmacies, campagnes de dépistage



Pourquoi ?

Orienter vite vers un test de confirmation

537 M

adultes diabétiques dans le monde

1 sur 2

ne sait pas qu'il est malade

Source : Atlas FID 2021

Les données : 768 patientes, 8 mesures

768
patientes

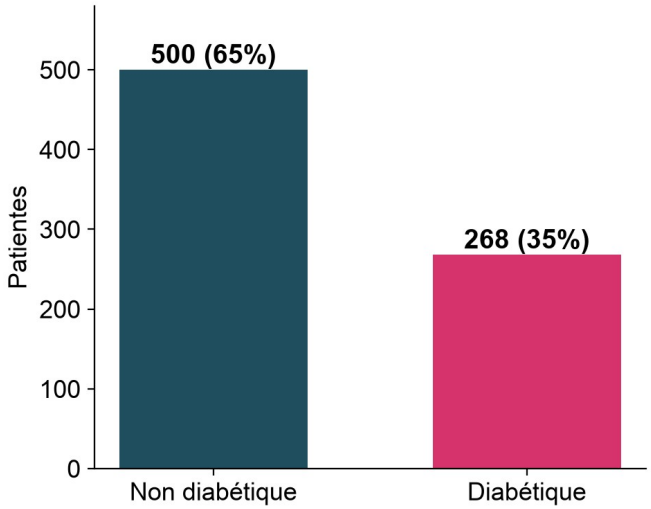
8
mesures

1
cible

Source : Pima Indians Diabetes (femmes ≥ 21 ans)

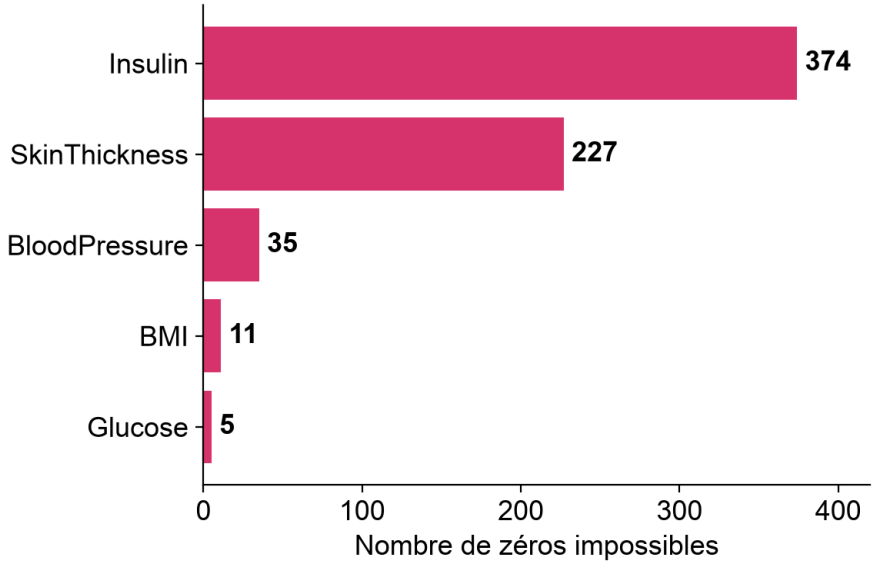
Variables : grossesses, glycémie, tension, peau, insuline, IMC, hérédité, âge

Cible : Outcome (1 = diabétique)



Classes déséquilibrées : 65 % / 35 %

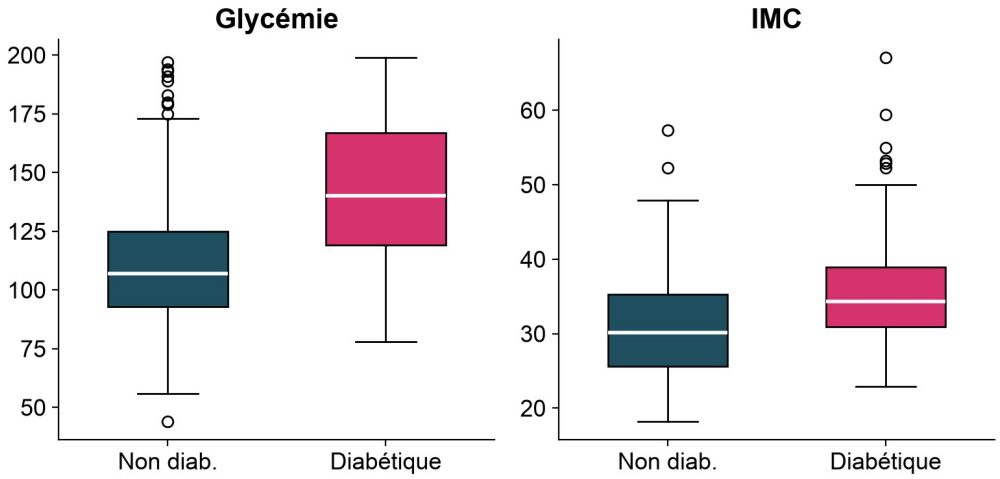
Nettoyage : des zéros impossibles cachés



- 0 doublon, 0 case vide… en apparence
- 652 zéros impossibles (tension 0, IMC 0)
- Zéros → valeurs manquantes (NaN)
- Remplacées par la médiane dans le pipeline

Insuline : 49 % de zéros !

Constats : la glycémie fait la différence



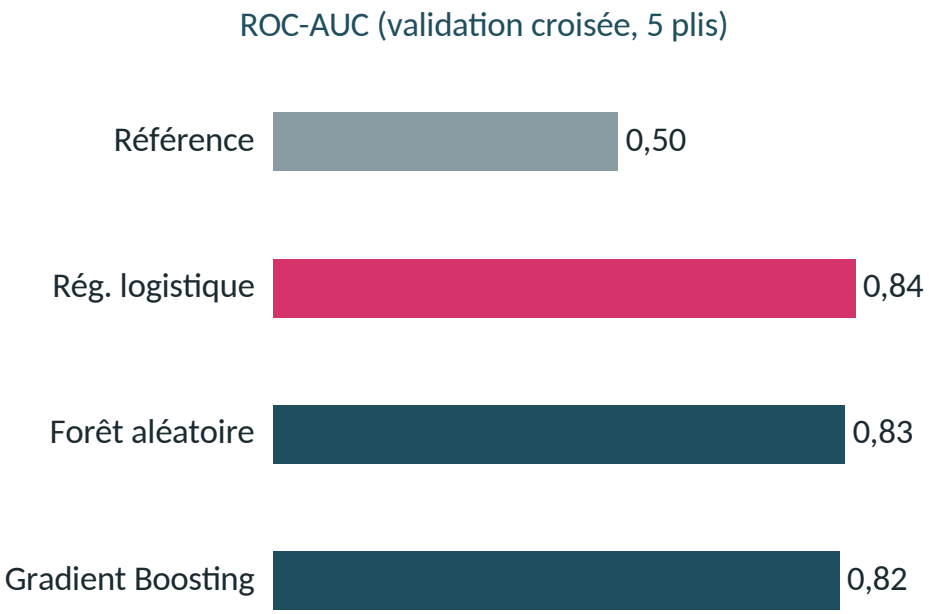
142 vs 111
glycémie moyenne (diab. / non)

35 vs 31
IMC moyen

37 vs 31 ans
âge moyen

Glycémie = variable la plus liée au diabète (corrélation 0,50)

Trois modèles face à une référence



Référence
Toujours « non diabétique ». Score à battre.

Régression logistique
Une formule pondérée. Simple, explicable.

Forêt aléatoire
300 arbres qui votent.

Gradient Boosting
Chaque arbre corrige le précédent.

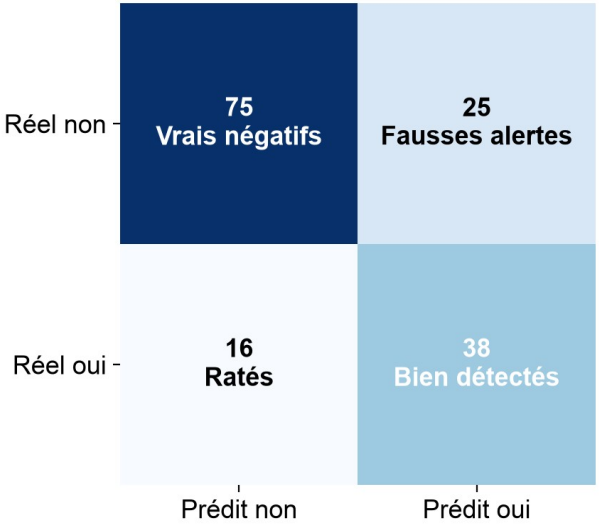
Découpage 80 / 20 : 614 entraînement · 154 test

Le gagnant : la régression logistique

0,84
ROC-AUC (référence : 0,50)

70 %
des diabétiques détectées

- Stable et sans sur-apprentissage (0,85 entraînement / 0,84 CV)
- Forêt : 0,999 à l'entraînement → apprend par cœur
- Seuil 0,4 → 83 % des diabétiques détectées



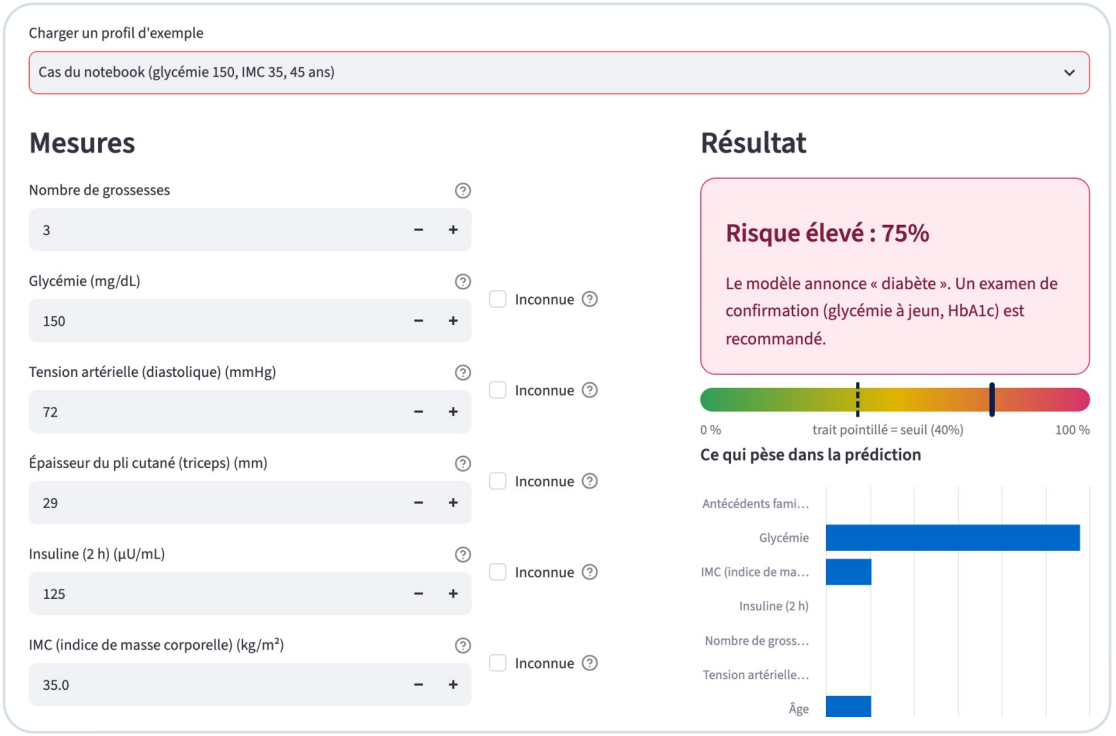
Test : 154 patientes jamais vues

Place à la démonstration

Application Streamlit · un cas réel saisi, une prédiction affichée



L'application en action



8 mesures

saisies en quelques secondes

Risque en %

avec une jauge et le seuil de décision

Explication

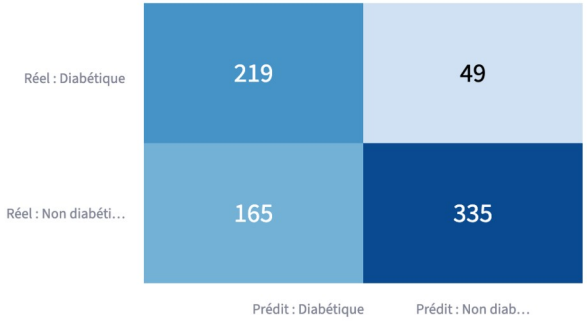
les facteurs qui pèsent le plus

diabetescope.streamlit.app

Les performances, en direct

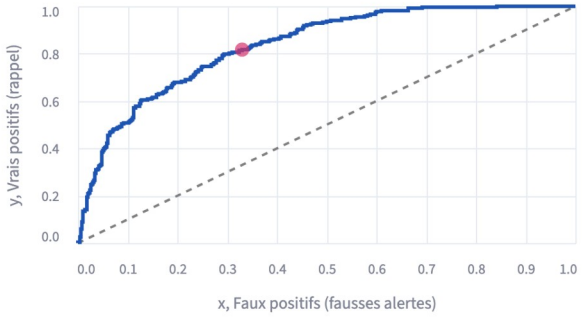
Accuracy	Précision	Rappel	F1	ROC-AUC
0.72	0.57	0.82	0.67	0.83

Matrice de confusion



49 cas manqués (faux négatifs) et 165 fausses alertes (faux positifs).

Courbe ROC



Le point rose indique le seuil actuel ; la ligne pointillée représente le hasard.

Évaluation en validation croisée (5 plis) sur les 768 patientes

82 %
des diabétiques détectées au seuil 0,4

0,83
de ROC-AUC (hasard : 0,50)

Seuil réglable
pour arbitrer rappel et fausses alertes

Bootcamp validé



Certificat

de participation au bootcamp IA et Machine Learning

Swiss UMEF

University, Umef Tech Community

GalsenAI

Ambassador Program

Merci au jury, aux mentors et à l'équipe GlucoScan