ÉQUIPE GLUCOSCAN

Dépistage du diabète

Prédire le risque à partir de 8 mesures médicales simples

UMEF AI Bootcamp · Demo Day



Photo : David-i98, CC BY-SA 3.0, Wikimedia Commons

Le problème : repérer le risque tôt



Que prédit-on ?

Diabétique (1) ou non (0) → classification



Pour qui ?

Centres de santé, pharmacies, campagnes de dépistage



Pourquoi ?

Orienter vite vers un test de confirmation

537 M

adultes diabétiques dans le monde

1 sur 2

ne sait pas qu'il est malade

Source : Atlas FID 2021

Les données : 768 patientes, 8 mesures

768
patientes

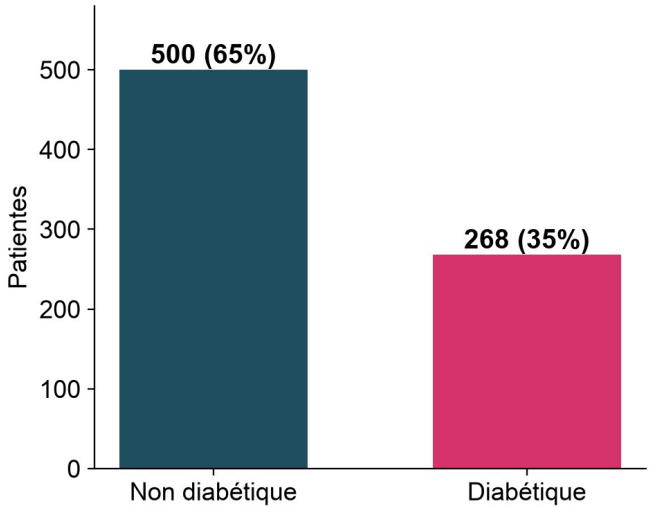
8
mesures

1
cible

Source : Pima Indians Diabetes (femmes ≥ 21 ans)

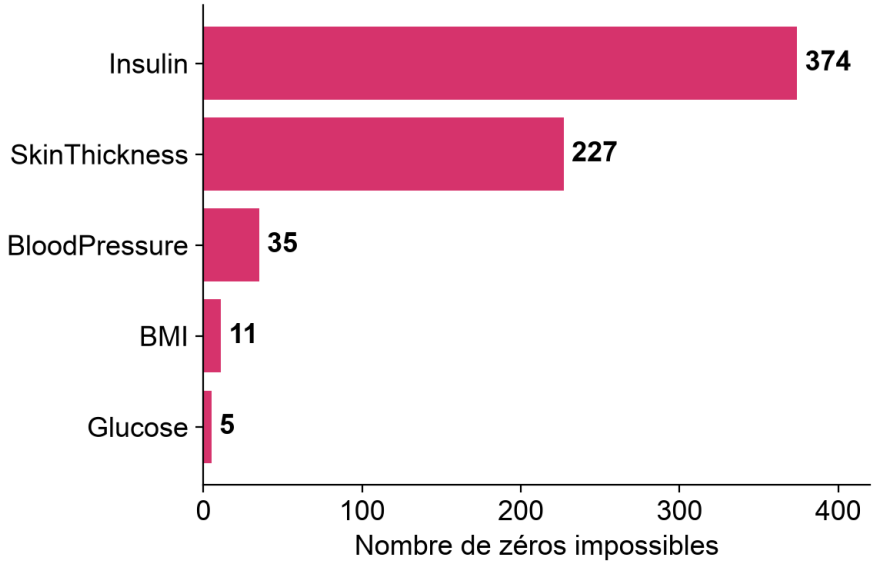
Variables : grossesses, glycémie, tension, peau, insuline, IMC, hérédité, âge

Cible : Outcome (1 = diabétique)



Classes déséquilibrées : 65 % / 35 %

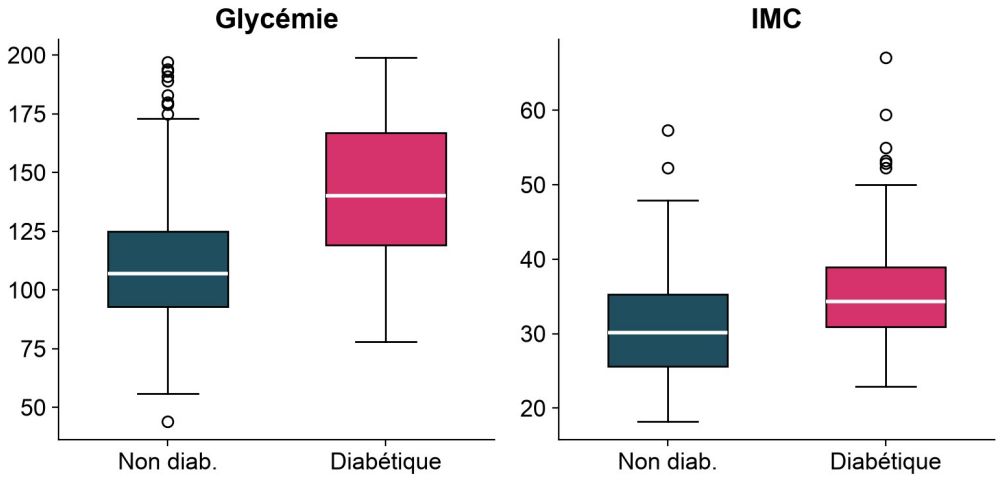
Nettoyage : des zéros impossibles cachés



- 0 doublon, 0 case vide… en apparence
- 652 zéros impossibles (tension 0, IMC 0)
- Zéros → valeurs manquantes (NaN)
- Remplacées par la médiane dans le pipeline

Insuline : 49 % de zéros !

Constats : la glycémie fait la différence



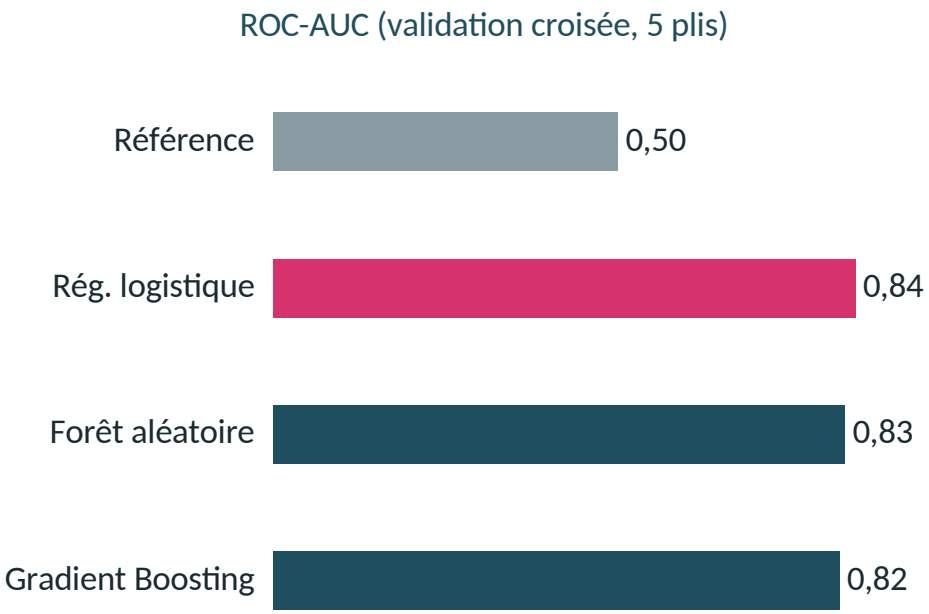
142 vs 111
glycémie moyenne (diab. / non)

35 vs 31
IMC moyen

37 vs 31 ans
âge moyen

Glycémie = variable la plus liée au diabète (corrélation 0,50)

Trois modèles face à une référence



Référence
Toujours « non diabétique ». Score à battre.

Régression logistique
Une formule pondérée. Simple, explicable.

Forêt aléatoire
300 arbres qui votent.

Gradient Boosting
Chaque arbre corrige le précédent.

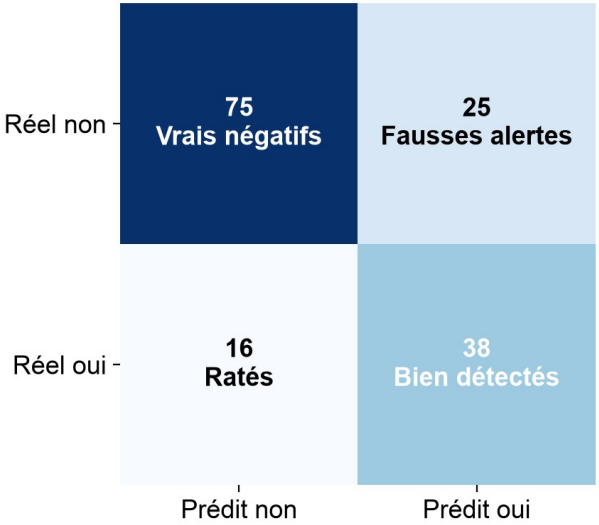
Découpage 80 / 20 : 614 entraînement · 154 test

Le gagnant : la régression logistique

0,84
ROC-AUC (référence : 0,50)

70 %
des diabétiques détectées

- Stable et sans sur-apprentissage (0,85 entraînement / 0,84 CV)
- Forêt : 0,999 à l'entraînement → apprend par cœur
- Seuil 0,4 → 83 % des diabétiques détectées



Test : 154 patientes jamais vues

Place à la démonstration

Application Streamlit · un cas réel saisi, une prédiction affichée

